

STRATEGIC LAKEHOUSE

GlobalTrade Solutions

Cahier des Charges Fonctionnel

Fonctionnalités priorisées · Matrice des risques · Conformité & Accessibilité Numérique

Objectif du document

Ce cahier des charges fonctionnel liste les fonctionnalités attendues du Strategic Lakehouse, priorisées selon la méthode MoSCoW (Must have / Should have / Could have / Won't have). Chaque fonctionnalité est décrite avec son critère d'acceptation, afin de cadrer la spécification technique et le périmètre du POC. Il intègre également la matrice des risques clés et les exigences de conformité et d'accessibilité numérique.

Méthode de priorisation MoSCoW

Niveau	Signification	Usage dans ce projet
M — Must have	Indispensable, sans quoi le projet échoue	Cœur du pipeline Bronze/Silver/Gold + exposition API
S — Should have	Important mais non bloquant à court terme	Sécurité des accès, dashboard
C — Could have	Souhaitable si le temps le permet	Catalogue de données, monitoring avancé
W — Won't have (cette itération)	Explicitement hors périmètre du POC	Déploiement cloud réel, ML/IA avancée

Fonctionnalités priorisées

F1 — Ingestion des données sources (Bronze)

Domaine	Ingestion
Description	Le système doit permettre l'ingestion de fichiers bruts provenant des silos existants (ERP on-premise, CRM SaaS, fichiers analytiques) sans transformation, en mode append-only, afin de conserver une traçabilité complète des données d'origine.
Critère d'acceptation	Un fichier CSV simulant les exports ERP/CRM (ex : g_fact_sales.csv, g_dim_customers.csv) est ingéré dans la couche Bronze en conservant le format brut, l'horodatage d'ingestion et la source d'origine, sans perte de lignes.
Priorité MoSCoW	Must have

F2 — Nettoyage, typage et dédoublonnage (Silver)

Domaine	Stockage / Qualité
Description	Le système doit transformer les données Bronze en données exploitables : typage des colonnes, suppression des doublons, gestion des valeurs manquantes, et mise en quarantaine des lignes en erreur.
Critère d'acceptation	À partir d'un jeu de données Bronze contenant des doublons et des valeurs incohérentes, la table Silver produite ne contient aucun doublon, les types de colonnes sont conformes au

	schéma cible, et les lignes rejetées sont journalisées dans une table de quarantaine consultable.
Priorité MoSCoW	Must have

F3 — Stockage en couches Bronze / Silver / Gold

Domaine	Stockage
Description	Le système doit organiser le stockage selon une architecture médallion à trois niveaux (Bronze : données brutes, Silver : données nettoyées, Gold : données agrégées prêtes à l'emploi), avec persistance sur stockage objet ou local.
Critère d'acceptation	Les trois couches sont physiquement séparées (dossiers ou tables distincts), chaque couche est accessible indépendamment, et le passage d'une couche à l'autre est tracé (job/log d'exécution horodaté).
Priorité MoSCoW	Must have

F4 — Requêtage et agrégation des KPIs (Gold)

Domaine	Requêtage
Description	Le système doit permettre le calcul et le requêtage rapide d'indicateurs métier agrégés (ex : ventes journalières, chiffre d'affaires par canal/pays) à partir de la couche Silver, en s'appuyant sur un moteur de traitement performant (DuckDB/Pandas).
Critère d'acceptation	Une requête d'agrégation sur un volume de test (ex : 10 000 lignes) renvoie un résultat exact et cohérent avec un calcul de référence, en moins de 1 seconde.
Priorité MoSCoW	Must have

F5 — API d'exposition BI

Domaine	API BI
Description	Le système doit exposer les KPIs de la couche Gold via une API REST (FastAPI/Flask) consommable par un dashboard ou un outil BI externe, avec une réponse au format JSON structuré.
Critère d'acceptation	Un appel GET /api/v1/kpi/daily-sales retourne un code HTTP 200 avec une charge utile JSON valide, contenant les KPIs demandés, en moins de 200 ms sur le jeu de données du POC.
Priorité MoSCoW	Must have

F6 — Gestion des droits et des accès

Domaine	Sécurité
---------	----------

Description	Le système doit restreindre l'accès aux données selon le profil utilisateur (ex : Analyste BI en lecture seule sur Gold, Data Scientist en lecture sur Silver, Administrateur en écriture sur toutes les couches), afin de respecter le principe de moindre privilège et la conformité RGPD.
Critère d'acceptation	Un utilisateur non autorisé recevant un token/rôle « lecture Gold » obtient une réponse 403 (Forbidden) lors d'une tentative d'accès à la couche Silver ou Bronze.
Priorité MoSCoW	Should have

F7 — Interface de visualisation (Dashboard)

Domaine	Restitution
Description	Le système doit proposer une interface web minimaliste affichant les KPIs en temps réel à partir de l'API BI, respectant les normes d'accessibilité numérique (RGAA/WCAG) : balises sémantiques, contrastes suffisants, navigation clavier.
Critère d'acceptation	La page affiche un KPI actualisé après appel API, utilise des balises <h1>/<label> sémantiques, obtient un score de contraste conforme WCAG AA (ratio $\geq 4.5:1$), et est navigable entièrement au clavier.
Priorité MoSCoW	Should have

F8 — Catalogue de données et traçabilité (lineage)

Domaine	Gouvernance
Description	Le système pourrait fournir un catalogue listant les tables disponibles par couche, leur schéma, leur origine et leur date de dernière mise à jour, afin de préparer la gouvernance et l'exploitation future par des agents IA.
Critère d'acceptation	Un fichier ou endpoint de métadonnées liste au minimum : nom de la table, couche, colonnes, source d'origine, date de dernière ingestion.
Priorité MoSCoW	Could have

Synthèse des priorités

#	Fonctionnalité	Domaine	MoSCoW
F1	Ingestion des données sources (Bronze)	Ingestion	Must have
F2	Nettoyage, typage et dédoublonnage (Silver)	Stockage / Qualité	Must have
F3	Stockage en couches Bronze / Silver / Gold	Stockage	Must have
F4	Requêtage et agrégation des KPIs (Gold)	Requêtage	Must have
F5	API d'exposition BI	API BI	Must have
F6	Gestion des droits et des accès	Sécurité	Should have

#	Fonctionnalité	Domaine	MoSCoW
F7	Interface de visualisation (Dashboard)	Restitution	Should have
F8	Catalogue de données et traçabilité (lineage)	Gouvernance	Could have

Hors périmètre (Won't have — cette itération) : déploiement cloud réel, orchestration temps réel (streaming), modèles de Machine Learning avancés, authentification SSO d'entreprise.

Matrice des risques clés

#	Risque	Description	Impact	Probabilité	Mitigation
R1	RGPD / conformité données personnelles	Les données CRM contiennent des données à caractère personnel (email, nom, historique client) ingérées et dupliquées à travers les couches Bronze/Silver/Gold sans contrôle.	Élevé	Moyenne	Anonymisation/pseudonymisation des champs sensibles dès la couche Silver (hashage de l'email en unified_customer_id), registre des traitements, durée de rétention définie par couche, droit à l'effacement documenté dans le pipeline.
R2	Perte de données	Corruption ou suppression accidentelle d'un fichier source ou d'une table lors d'un job d'ingestion/transformation défaillant.	Élevé	Faible à moyenne	Stockage Bronze en append-only (jamais d'écrasement), versionnement des fichiers, sauvegardes régulières automatisées, tests de restauration périodiques, réplication du stockage objet.
R3	Indisponibilité du service	Panne de l'API BI ou du moteur de traitement empêchant l'accès aux KPIs par le dashboard ou les analystes.	Moyen	Moyenne	Health-check automatisé sur l'API, timeout et retry côté client, cache des derniers KPIs calculés, plan de reprise d'activité (PRA) documenté avec RTO/RPO cibles.
R4	Sécurité des accès	Accès non autorisé aux couches Silver/Bronze contenant des données brutes ou sensibles, ou usurpation de rôle.	Élevé	Moyenne	Contrôle d'accès basé sur les rôles (RBAC) par couche, authentification par token (API key/JWT), chiffrement des données au repos et en transit (TLS), journalisation de tous les accès.
R5	Dette technique	Accumulation de scripts ad hoc non maintenables, absence de tests, dépendance à des choix techniques non documentés au fil du POC.	Moyen	Élevée si non traitée	Versionnement Git avec revue de code, README de lancement à jour, tests automatisés sur les transformations Silver, documentation du schéma de données, choix technologiques justifiés et consignés.

Conformité et accessibilité numérique

6.1 Normes de référence

- RGAA (Référentiel Général d'Amélioration de l'Accessibilité) — référentiel français applicable aux services numériques, transposant les exigences européennes d'accessibilité.
- WCAG 2.1 (Web Content Accessibility Guidelines, niveau AA) — standard international du W3C sur lequel s'appuie le RGAA, structuré autour de 4 principes : perceptible, utilisable, compréhensible, robuste.
- RGPD (Règlement Général sur la Protection des Données) — en complément, pour le traitement des données personnelles affichées dans le dashboard (cf. matrice des risques, R1).

6.2 Mesures concrètes prévues pour le dashboard

1. **Gestion des contrastes pour les malvoyants** — respect d'un ratio de contraste minimal de 4.5:1 (texte normal) et 3:1 (texte large/graphiques) entre les éléments des KPIs et leur arrière-plan, conformément au critère WCAG 1.4.3.
2. **Compatibilité avec les lecteurs d'écran pour les KPI** — utilisation de balises HTML sémantiques (<h1>, <table>, <label>) et d'attributs ARIA (aria-live pour les KPIs actualisés dynamiquement, aria-label pour les graphiques) afin que la valeur et le contexte de chaque indicateur soient restitués vocalement.
3. **Navigation clavier intégrale** — tous les éléments interactifs (filtres, boutons de rafraîchissement, liens) sont accessibles et activables au clavier (Tab/Entrée/Échap), avec un focus visuel clairement identifiable, sans piège au clavier (keyboard trap).