

STRATEGIC LAKEHOUSE

GlobalTrade Solutions

Synthèse Diagnostic & Recommandations

Analyse comparative des architectures cibles · Recommandation stratégique

À la demande de la direction générale, voici le rapport d'architecture et de cadrage pour la modernisation du système d'information décisionnel de la société GlobalTrade. Cette étude pose les bases méthodologiques et comparatives nécessaires avant le lancement de notre prototype (POC) fonctionnel.

Cartographie du SI existant et diagnostic du silotage

Niveau fonctionnel : les processus métiers

Au niveau fonctionnel, la chaîne de valeur de GlobalTrade Solutions repose sur trois grands piliers qui s'articulent de manière séquentielle mais cloisonnée :

- **La gestion des opérations et des stocks (ERP)** : Enregistrement des transactions commerciales, suivi des volumes de ventes et gestion des cycles de vie des produits.
- **La relation client et l'engagement (CRM)** : Capture des données clients, suivi du parcours utilisateur et exécution des campagnes marketing.
- **L'analyse de performance (Analytics)** : Consolidation des indicateurs de vente par canal, par jour ou par zone géographique afin de produire des rapports de pilotage.

Niveau applicatif : les silos technologiques

L'implémentation technique actuelle segmente ces processus en trois environnements distincts, entraînant une rupture de la continuité des données :

- **Silo ERP on-prem (GlobalTrade ERP)** : Héberge des données structurées et relationnelles critiques (`g_dim_products`, `g_fact_sales`). Son accessibilité est limitée par des contraintes de performance opérationnelle (risque de surcharge de la base de production).
- **Silo CRM SaaS (GlobalTrade CRM Cloud)** : Stocke les profils clients et l'historique des interactions (dérivés de `g_dim_customers`). C'est un environnement cloud propriétaire dont l'extraction de données nécessite des API ou des exports manuels.
- **Silo fichiers analytiques (GlobalTrade Analytics)** : Des fichiers CSV/Parquet (exports de ventes agrégées par jour/canal/pays) coexistent de façon volatile sur des partages réseau, déconnectés des mises à jour en temps réel de l'ERP.

Impacts sur la chaîne de valeur analytique

L'analyse croisée de ces sources met en évidence un cloisonnement technique sévère :

- **Rupture de la réconciliation** : Lier une campagne marketing (CRM) à un achat final (ERP) exige des jointures complexes, souvent réalisées manuellement sur des fichiers plats.
- **Incohérence des indicateurs** : La prolifération de versions dérivées de `g_fact_sales` au sein du silo analytique crée un effet "boîte noire" où différentes équipes calculent un même indicateur avec des règles d'agrégation divergentes.
- **Latence décisionnelle** : L'analyste subit le rythme des processus d'extraction (hebdomadaires ou mensuels), empêchant un pilotage agile et proactif.

Approche data-driven et préparation à l'IA agentique

Pour dépasser ce constat, le SI doit évoluer d'une logique de "rapports a posteriori" vers un écosystème *data-driven* (piloté par la donnée). L'unification de ces silos ne sert pas uniquement la Business Intelligence classique, elle prépare l'infrastructure à l'arrivée d'**agents IA autonomes**.

Pour que des agents IA puissent demain interagir de manière fiable avec le SI (par exemple, détecter une baisse de vente sur un produit, analyser le segment client concerné et déclencher une campagne CRM corrective automatiquement), l'architecture doit impérativement garantir :

1. **Un catalogue de données unifié** : Les métadonnées doivent être centralisées pour qu'un grand modèle de langage (LLM) comprenne instantanément la relation entre un identifiant de client et une clé produit.
2. **Des pipelines en temps réel ou micro-batch** : L'IA ne peut pas agir efficacement sur des données obsolètes de plusieurs semaines.

Une couche de sémantique partagée : Les concepts métiers (ex. : la définition d'un "client actif") doivent être codifiés de manière unique pour éviter que l'IA ne génère des hallucinations basées sur des interprétations contradictoires.

Analyse comparative des architectures cibles

Trois architectures cibles ont été évaluées pour répondre au besoin d'unification du SI de GlobalTrade Solutions : le Data Warehouse Cloud, le Data Lake et le Lakehouse. Le tableau ci-dessous synthétise leur positionnement sur cinq critères stratégiques : coût, scalabilité, latence, conformité RGPD et aptitude à l'IA.

Critère	Data Warehouse Cloud	Data Lake	Lakehouse
Coût	Élevé à l'échelle : stockage et calcul couplés, formats propriétaires, facturation qui croît fortement avec le volume. Investissement initial et TCO conséquents (licences, dimensionnement).	Très faible en stockage (object storage, pay-as-you-go), jusqu'à 77-95 % moins cher qu'un warehouse pour le stockage brut. Mais les coûts de traitement/gouvernance grimpent si les données restent mal cataloguées.	Optimisé : stockage low-cost du data lake + calcul découplé, avec gouvernance intégrée limitant la duplication. Des migrations documentées rapportent jusqu'à ~80 % de réduction de coût total vs un warehouse classique.
Scalabilité	Bonne mais coûteuse à grande échelle : stockage et calcul souvent liés, scale-up onéreux au-delà de quelques dizaines de To.	Quasi illimitée : stockage et calcul séparés, ajout de capacité sans limite technique forte, adapté aux très gros volumes hétérogènes.	Très bonne : hérite de la scalabilité du lake (stockage objet) tout en gardant indexation/cache pour éviter la dégradation des performances à grande échelle.
Latence	Excellente pour les requêtes structurées : indexation, vues matérialisées, colonnes optimisées → réponses en secondes sur de gros volumes.	Faible nativement : schema-on-read, absence d'indexation par défaut, temps de réponse plus longs pour des requêtes ad hoc sur données brutes.	Bonne à très bonne : formats de table ouverts (Delta/Iceberg/Hudi) avec ACID, indexation et cache. Des cas documentés montrent une latence réduite de 12-24 h à quelques minutes via des mises à jour incrémentales continues.
Conformité RGPD	Point fort historique : contrôle d'accès par rôle (RBAC), audit logs, chiffrement, masquage de données, certifications sectorielles (SOX, HIPAA, RGPD).	Point faible : gouvernance à construire soi-même (catalogues externes type Glue/Ranger), risque de « data swamp », droit à l'effacement difficile à appliquer sur des fichiers bruts immuables.	Bonne et en progression rapide : catalogues intégrés (ex. Unity Catalog, Delta Sharing) simplifiant la conformité RGPD/HIPAA, transactions ACID permettant des suppressions/mises à jour ciblées (droit à l'oubli), traçabilité (lineage) native.

Critère	Data Warehouse Cloud	Data Lake	Lakehouse
Aptitude à l'IA	Limitée : conçu pour la donnée structurée et le reporting, peu adapté aux données non structurées (images, logs, texte libre) nécessaires au Machine Learning.	Très bonne : stockage de tout type de données dans leur format natif, base idéale pour l'entraînement de modèles ML/IA à grande échelle.	Excellente : unifie BI et IA sur une même copie des données (Silver/Gold), donne aux data scientists un accès direct aux données brutes ET nettoyées sans duplication, architecture pensée pour les futurs agents IA.

Constat : le Data Warehouse excelle en gouvernance et performance sur données structurées mais coûte cher à l'échelle et bride l'IA. Le Data Lake offre coût et scalabilité imbattables mais expose GlobalTrade à un risque de « data swamp » et de non-conformité RGPD. Le Lakehouse combine les forces des deux modèles sans en cumuler les faiblesses, ce qui en fait la trajectoire la plus cohérente avec la fragmentation actuelle du SI (ERP on-premise, CRM SaaS, fichiers isolés) et les ambitions IA de l'entreprise.

Recommandation stratégique : le choix du Lakehouse

À l'attention du comité de direction de GlobalTrade Solutions.

L'analyse du système d'information révèle que la fragmentation entre GlobalTrade ERP, GlobalTrade CRM et les fichiers analytiques isole les actifs de données et freine l'agilité commerciale. Pour transformer ce capital fragmenté en levier de performance, nous recommandons le déploiement d'une architecture Lakehouse unifiée. Ce choix ne représente pas une simple mise à jour technique, mais une décision stratégique articulée autour de cinq arguments majeurs et démontrables.

Argument 1 — Une source unique de vérité qui met fin au silotage

GlobalTrade opère aujourd'hui trois silos déconnectés (ERP on-premise, CRM SaaS, fichiers analytiques), sans gouvernance commune, ce qui empêche toute vision consolidée et fiabilise mal les KPIs remontés au COMEX. Le Lakehouse centralise l'ensemble de ces flux dans un modèle en couches Bronze/Silver/Gold, où chaque donnée n'existe qu'une seule fois, nettoyée et tracée.

Le POC du projet en constitue la meilleure preuve, avec l'ingestion d'exports ERP et CRM dans une même couche Bronze pour produire une table Silver unifiée (SILVER_CUSTOMERS / SILVER_SALES) exposée par une API unique — la duplication de données entre silos disparaît.

Argument 2 — Une maîtrise des coûts et une scalabilité alignées sur la croissance

Contrairement à un Data Warehouse Cloud dont la facture croît avec le volume stocké, le Lakehouse repose sur un stockage objet low-cost découplé du calcul, comme le data lake. Des retours d'expérience documentés montrent des réductions de coût total de l'ordre de 80 % lors de migrations d'un warehouse classique vers une architecture lakehouse, tout en réduisant la latence de traitement de plusieurs heures à quelques minutes.

Le choix technique du POC le confirme, notamment via l'utilisation de DuckDB/Pandas sur fichiers Parquet/CSV qui ne nécessite aucune licence propriétaire et peut scaler horizontalement sans réécriture applicative si GlobalTrade migre vers un stockage cloud (S3, ADLS, GCS).

Argument 3 — Une plateforme prête pour la conformité RGPD et les futurs usages IA

Le Lakehouse intègre nativement des mécanismes que le data lake n'offre pas seul : transactions ACID permettant des suppressions ciblées (droit à l'effacement RGPD), traçabilité (lineage) des données, et catalogue de métadonnées. Il ouvre simultanément la voie aux futurs usages d'IA agentique, en donnant aux modèles un accès direct aux données nettoyées (Silver) sans dupliquer ni fragiliser la gouvernance.

La mise en place de la table de quarantaine et des rôles d'accès différenciés en témoigne, ces éléments étant prévus dans le cahier des charges fonctionnel et directement hérités des principes de gouvernance du Lakehouse.

Accessibilité : un levier d'adoption complémentaire

Au-delà des trois arguments techniques, l'accessibilité numérique du futur dashboard (conformité RGAA/WCAG) constitue un levier d'adoption transverse : elle garantit que l'ensemble des collaborateurs de GlobalTrade, y compris les personnes en situation de handicap, peuvent exploiter les KPIs sans dépendre d'aménagements spécifiques, ce qui réduit la dette technique de conformité et élargit l'audience effective de l'outil dès sa mise en production.

Convergence de la BI et de l'intelligence artificielle sur une plateforme unique

Traditionnellement, les entreprises s'imposent le maintien de deux infrastructures coûteuses : un Data Lake pour l'ingénierie des données et la science des données, et un Data Warehouse pour les rapports décisionnels (BI).

Le Lakehouse brise cette dualité. En implémentant une couche de stockage ouverte dotée de transactions ACID (comme Delta Lake ou Apache Iceberg), nous permettons aux analystes de requêter les ventes historiques avec la rapidité d'un entrepôt de données classique, tout en offrant aux futurs agents IA un accès direct aux formats de fichiers dont ils ont besoin pour l'apprentissage et le raisonnement sémantique. L'entreprise élimine ainsi les coûts de duplication et de synchronisation entre deux systèmes natifs distincts.

Conclusion : le Lakehouse n'est pas une mode technologique mais la réponse structurelle la plus cohérente à la fragmentation actuelle du SI de GlobalTrade, à ses contraintes de coût, et à sa trajectoire vers l'IA agentique.